



WYDZIAŁ ZARZĄDZANIA
I EKONOMII

Uczenie maszynowe w Pythonie

#1: Wprowadzenie

Michał Laskowski · 26 września, 9:00–12:45

O przedmiocie

- Zgłębienie i kontynuacja kursu „**Podstawy uczenia maszynowego**” na poziomie średnio zaawansowanym
- Pełny workflow projektu ML
dane → cechy → model → ocena → interpretacja
- **Forma warsztatowa:** kluczowa teoria, pracy na danych w grupach, Q&A
- **Narzędzia:** Python, Google Colab, Git/GitHub, Pandas, NumPy, scikit-learn

28 h

warsztatowych

6

zajęć

1

projekt końcowy

O mnie

- **Michał Laskowski** - Senior Data Scientist w WriteWise (Boston, USA)
- **Wykształcenie:**
inżynierskie – Politechnika Gdańska (ETI & ZiE), Inżynieria Danych
magisterskie – Massachusetts Institute of Technology (MIT), Business Analytics
- **Doświadczenie:** ponad 5 lat pracy z danymi i machine learningiem w branżach healthcare, pharma i FMCG; doświadczenie jako Research Assistant na MIT oraz Politechnice Gdańskiej
- **Wybrane projekty ML:**
 - opracowanie modeli AI i optymalizacyjnych dla ponad 10 szpitali i instytucji w USA, Indiach i Grecji, wspierających poprawę efektywności operacyjnej i wyników leczenia
 - opracowanie modelu optymalizacyjnego dla laboratoriów kontroli jakości firmy
 - projekty z zakresu telekomunikacji, obejmujące modelowanie propagacji sygnału i zastosowanie metod statystycznego uczenia maszynowego
 - rozwój modeli NLP, m.in. do analizy sentymentu, modelowania tematów i Explainable AI (XAI)
- **Po godzinach:** pasjonat sportu; przez blisko dekadę trenowałem pływanie



Poznajmy się!

Krótką rundą - trzy pytania na osobę:

1 Kim jesteś zawodowo i z jakiej branży pochodzisz?

2 Jakie masz doświadczenie z Pythonem i uczeniem maszynowym?

3 Czego chcesz się nauczyć - jaki problem chcesz rozwiązać po kursie?

Czym jest uczenie maszynowe?

Czym różni się programowanie klasyczne od uczenia maszynowego?

**Programowanie
klasyczne**



**Uczenie
maszynowe**



W ML nie programujemy reguł - komputer wyprowadza je sam z danych i przykładowych odpowiedzi.

AI, uczenie maszynowe, deep learning, GenAI

Sztuczna inteligencja (AI)

Uczenie maszynowe (ML)

Klasyczny ML

- Modele liniowe
- Drzewa decyzyjne
- Ensemble learning
- Klasteryzacja
- ...

Deep learning

Generatywna AI

(np. ChatGPT,
Claude, Gemini)

- **AI** - systemy wykonujące zadania kojarzone z ludzką inteligencją
- **Uczenie maszynowe** - modele, które uczą się reguł z danych
- **Deep learning** - wielowarstwowe sieci neuronowe: obraz, dźwięk, język
- **Generatywna AI** - modele tworzące tekst, obraz i kod

Trzy podstawowe zadania klasycznego ML

Klasyfikacja

uczenie nadzorowane

Przypisujemy obserwację do jednej z kategorii.

Przykłady:

- czy pacjent wróci do szpitala w 30 dni
- spam czy nie spam
- który klient zrezygnuje z abonamentu

Regresja

uczenie nadzorowane

Przewidujemy liczbę - wartość ciągłą.

Przykłady:

- cena mieszkania w PLN
- prognoza sprzedaży na kolejny tydzień
- czas dostawy w minutach

Klasteryzacja

uczenie nienadzorowane

Szukamy grup w danych bez znanych odpowiedzi.

Przykłady:

- segmentacja klientów
- grupowanie podobnych produktów
- wykrywanie nietypowych transakcji

Klasyfikacja i regresja - mamy w danych kolumnę z odpowiedziami. Klasteryzacja - nie mamy jej wcale.

Co będziecie umieli po kursie?

- ✓ przygotować dane do modelowania: braki, zmienne kategoryczne, skalowanie
- ✓ budować kompletne pipeline'y ML w scikit-learn
- ✓ trenować modele drzewiaste, boosting & bagging
- ✓ stosować uczenie nienadzorowane: klasteryzację i redukcję wymiarowości
- ✓ rzetelnie oceniać modele: metryki, walidacja krzyżowa, strojenie hiperparametrów
- ✓ wyjaśniać predykcje modeli (XAI) i rozpoznawać bias w danych
- ✓ poznawać dokładnie najczęściej stosowane metody uczenia maszynowego i wykorzystywać je w praktyce

Każdy punkt przećwiczymy na prawdziwych zbiorach danych.

Program kursu

19.09 · 9:00–12:45

Blok 1 - Workflow projektów uczenia maszynowego - **dzisiaj!**

24.10 · 9:00–12:45

Blok 2 - Przetwarzanie danych, inżynieria cech i ocena modeli

14.11 · 9:00–12:45

Blok 3 - Uczenie maszynowe oparte na drzewach, boosting'u i baggingu

12.12 · 9:00–12:45

Blok 4 - Uczenie nienadzorowane: klasteryzacja i redukcja wymiarowości

16.01 · 9:00–12:00

Blok 5 - Explainable AI, Responsible AI i inne kluczowe aspekty uczenia maszynowego

30.01 · 9:00–12:00

Blok 6 - Prezentacje projektów końcowych, dyskusja, Q&A

Projekt końcowy

- **Twój temat** - najlepiej realny problem z Twojej branży (dane publiczne np. [Kaggle](#), [UCI Repository](#))
- **Grupy:** 2-3 osobowe
- **Co oddajesz:** repozytorium GitHub, a w nim notebook wraz z krótkim raportem
- **Prezentacja:** 8-10 minut na ostatnim zjeździe + dyskusja
- Projekt jest **warunkiem koniecznym zaliczenia** kursu

do 12.12
zgłoszenie tematu



do 23.01
oddanie projektu
(lider zespołu przesyła na maila)



30.01
prezentacja

Zasady oceniania

50% projekt końcowy - warunek konieczny zaliczenia

10% prezentacja projektu

40% 2 zadania praktyczne między zjazdami

Progi ocen

$\geq 90\% \rightarrow 5,0$

$\geq 80\% \rightarrow 4,5$

$\geq 70\% \rightarrow 4,0$

$\geq 60\% \rightarrow 3,5$

$\geq 50\% \rightarrow 3,0$

Obecność: minimum 5 z 6 zjazdów

Organizacja i komunikacja

- **Materiały, zadania i kod:** repozytorium GitHub kursu - <https://github.com/ml-course-pg/ml-course-pg-2026>
- **Kontakt:** michallaskowski1@outlook.com
- **Na każdy zjazd:** laptop + konto Google - pracujemy w Google Colab
- **Rytm zajęć:** 3 bloki po ~45-60 minut, 15-20 minut przerwy pomiędzy
- **Narzędzia AI (ChatGPT itp.):** dozwolone jako wsparcie - warunek: rozumiesz i umiesz objaśnić swój kod

Pytania?



Śmiało - o program, zaliczenie, narzędzia... cokolwiek!

Na rozgrzewkę: quiz Kahoot!



kahoot.it

1. Wejdź na kahoot.it na telefonie lub laptopie
2. Wpisz PIN gry i swój nick - i gramy!

Szybka przejście przez podstawy ML - bez ocen, liczy się dobra zabawa :)